RL для вызова функций

Qwen3.5-2B / ToolACE / учебный срез BFCL

Лучшая конфигурация в этой серии - GRPO с составной наградой: overall 78.93% против 68.93% у исходной модели, прирост 10.00 п.п. Парный bootstrap даёт 95% интервал прироста [4.80; 15.47] п.п. Dr. GRPO близок к этому результату: 78.40%. Все три RL-запуска завершены на заранее выбранном 300-м шаге.

1. Данные и подготовка

Для обучения использован только Team-ACE/ToolACE, ревизия 6bda777c88d21e5a204703c1ee45597a8fa4f734. В исходных данных 11 300 диалогов. Сначала отложены 565 целых диалогов с seed 42, затем каждый диалог нарезан на префиксы до ответа ассистента после сообщения пользователя. Предыдущие ответы и результаты инструментов сохраняются в истории. Ответы сразу после tool-сообщений отдельными целями не становятся.

Описания функций приведены к JSON Schema, недопустимые символы в именах заменены подчёркиваниями. Тот же словарь замен применяется к эталонам. Сохраняется указанное в диалоге текущее время. Промпт собирается исходным chat template с enable_thinking=False; сам эталон в промпт не добавляется.

Выборка	Префиксы	Диалоги	С вызовом	Без вызова
train	11154	10150	9008	2146
validation	602	542	496	106

Исключены 518 диалогов с альтернативным описанием инструментов, 49 с неразбираемым синтаксисом вызова и один с нестандартной разметкой ответа. Также убраны 5 пустых целей, 82 длинных префикса и 36 повторов промпта. Ограничение длины - 2048 токенов, длинные примеры исключаются целиком. Проверка точного нормализованного совпадения вопросов с BFCL пересечений не нашла. Идентификаторы и SHA256 сохранены.

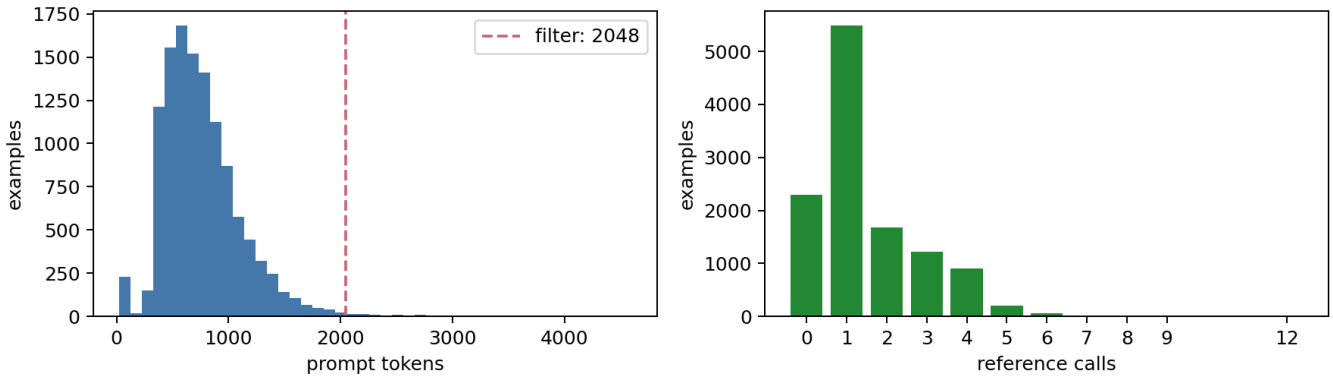


Рис. 1. Длины и число эталонных вызовов до фильтрации по длине и удаления повторов. Медиана промпта - 701 токен, 95-й процентиль - около 1404. Среди оставленных функций 16019 уникальных имён. Все эталонные аргументы проверены на соответствие схемам.

2. Награды и эксперименты

Ответ 1. Точная награда прямо связана с задачей, но у неё нет промежуточного сигнала: одна ошибка в аргументе обнуляет весь ответ. Составная награда дополнительно поощряет правильный выбор функции и части аргументов. Это помогает различать ответы, когда ни один из четырёх ещё не полностью правильный.

E - точное равенство мультимножеств полных вызовов, с учётом повторов и без учёта порядка. Числа 1 и 1.0 эквивалентны; у строк убираются только крайние пробелы. V - корректная разметка и соответствие вызовов схемам. F_n - F1 по мультимножеству имён функций. F_a - F1 по мультимножеству троек (функция, имя аргумента, значение). Если аргументов нет ни в эталоне, ни в ответе, $F_a = F_n$.

R_exact = E
R_shaped = $0.1V + 0.2F_n + 0.2F_a + 0.5E$

Обрезанный ответ даёт 0 в обеих наградах. Для задания с вызовом пустой ответ, неразобранная разметка или отсутствие вызова дают 0. Для задания без вызова обе награды равны 1 только при непустом корректном ответе без инструмента. Неполные генерации маскируются в policy loss. Используется тот же Qwen3CoderToolParser, что и в evaluator.

У F_a есть ограничение: при нескольких вызовах одной функции частичная награда не различает перестановку аргументов между вызовами. Полное соответствие E при этом остаётся нулевым. Для ответов без вызова оценивается решение не вызывать инструмент, а не полезность текста.

Ответ при эталоне weather(city='Paris')	R_exact	R_shaped
weather(city='Paris')	1.0	1.0
weather(city='London')	0.0	0.3
Незакрытый <tool_call>	0.0	0.0
Текст без вызова	0.0	0.0
Текст без вызова, когда эталон тоже без вызова	1.0	1.0

Это искусственные примеры для проверки функции награды; в обучение они не входят. Проверяются также повторы вызовов и разные функции без аргументов.

Ответ 4. Если все четыре награды одинаковы, R_i - mean(R) = 0. Advantage равен нулю и при делении на std + 10^{-4}, и без деления в Dr. GRPO. Policy-часть от такого запроса не обучает модель. При $\beta = 0.02$ может оставаться градиент KL-штрафа к исходной политике.

3. Конфигурации и ресурсы

Запуск	Изменение и гипотеза
grpo_exact	Точная награда напрямую поощряет правильный полный набор вызовов, но может давать мало различающихся наград внутри группы.
grpo_shaped	Частичная награда за функцию и аргументы даст сигнал даже там, где ни один ответ ещё не полностью правильный. Меняется только награда.
dr_grpo_shaped	Dr. GRPO уберёт зависимость веса токена от длины ответа и масштабирование по std группы. Проверяется весь этот вариант нормировки при той же составной награде.

Одна A100 80 GB PCIe, Python 3.12.16, PyTorch 2.11.0/CUDA 13.0, Transformers 5.9.0, TRL 1.16.0, PEFT 0.18.1 и vLLM 0.22.0. LoRA: r=16, alpha=32, dropout=0; q/k/v/o, gate/up/down, in_proj_qkv/z/a/b и out_proj. Исходные веса BF16, адаптеры FP32, SDPA, TF32, gradient checkpointing. AdamW fused, lr=2e-5, 10 шагов warmup, затем постоянный lr; weight decay=0.01, clip grad=0.3, beta=0.02. Batch=8, accumulation=4: 32 ответа, то есть 8 запросов с G=4 на шаг; num_iterations=1. Sampling: temperature=0.8, top_p=0.95, top_k=0, максимум 512 токенов. Seed данных и Trainer - 42, rollout engine - 0 (стандарт TRL для rank 0), финальная оценка - 42. Полные параметры и ревизия модели сохранены в runs/*/config.json и summary.json.

В GRPO advantage равен $(R_i - \text{mean}(R)) / (\text{std}(R) + 10^{-4})$, а токены усредняются внутри каждого ответа. В Dr. GRPO advantage = $R_i - \text{mean}(R)$; сумма по токенам делится на фиксированные 512 × число ответов. Эти две нормировки меняются вместе. Во всех вариантах ratio считается по токенам и используется симметричный clipping 0.2.

Запуск	Шаг	Время, с	Обучаемых параметров	Torch peak allocated, GiB
grpo_exact	300	5618.6	16 819 200	35.70
grpo_shaped	300	3722.5	16 819 200	35.50
dr_grpo_shaped	300	3583.9	16 819 200	35.73

Время включает инициализацию trainer и обучение. Память - максимум allocated в PyTorch, включая совместный процесс с rollout engine. Замер общего потребления через NVML отдельно не проводился.

Все основные запуски обучаются с исходных весов и имеют одинаковый бюджет шагов и запросов. Короткие предварительные проверки по два шага используются только для проверки кода и памяти. Их веса не переносятся в основные эксперименты.

4. Результаты

Оценка выполнена одним исходным evaluate.py на неизменённых 350 примерах. Токенизатор взят из фиксированной ревизии исходной модели. Для всех запусков: greedy, temperature=0, максимум 1024 новых токена, thinking отключён. LoRA перед оценкой объединена с базовыми весами.

Overall усредняет пять групп с одинаковыми весами. Внутри Multiple и Irrelevance сначала усредняются их две категории. Simple, Parallel и Parallel multiple содержат по 50 примеров, Multiple - 150, Irrelevance - 50.

Запуск	Overall	Simple	Multiple	Parallel	Parallel + multiple	Irrel.
base	68.93	68.00	78.67	56.00	80.00	62.00
grpo_exact	70.53	62.00	74.67	48.00	84.00	84.00
grpo_shaped	78.93	86.00	80.67	80.00	88.00	60.00
dr_grpo_shaped	78.40	80.00	82.00	74.00	88.00	68.00

Таблица 1. BFCL, значения в процентах.

RL относительно base	Разница, п.п.	95% bootstrap CI, п.п.
grpo_exact	+1.60	[-2.93; +6.13]
grpo_shaped	+10.00	[+4.80; +15.47]
dr_grpo_shaped	+9.47	[+5.07; +13.87]

Парный bootstrap: 3000 пересэмплирований внутри семи исходных категорий с сохранением весов overall. Интервал отражает неопределённость этой небольшой тестовой выборки. Каждый RL-запуск выполнен с одним seed.

ToolACE validation	Exact, %	Shaped	Call, %	No call, %
base	63.02	0.718	62.50	64.06
grpo_exact	77.60	0.842	70.31	92.19
grpo_shaped	73.44	0.799	72.66	75.00
dr_grpo_shaped	75.00	0.820	71.09	82.81

Отдельная диагностическая выборка: 64 префикса без вызова, 64 с одним вызовом и 64 с несколькими. Они отложены по диалогам до обучения. Для основной серии заранее выбран последний, 300-й шаг.

Ответ 2. Самое сильное контролируемое изменение - замена точной награды на составную: +8.40 п.п. overall при том же GRPO, 95% парный bootstrap CI [3.87; 13.20] п.п. Совпадают исходные веса, данные, seed, LoRA, lr и бюджет 300 шагов; меняется только награда. В Dr. GRPO одновременно меняются две нормировки, поэтому отдельно приписать эффект одной из них нельзя.

Для выбранной задачи предпочтителен GRPO с составной наградой по наблюдаемому overall. Его отрыв от Dr. GRPO всего 0.53 п.п., CI [-3.07; 4.00] п.п.; уверенного различия между ними эта выборка не показывает. У точной награды прирост лишь 1.60 п.п., CI включает ноль. Число верных ответов у base и grpo_exact одинаково: 251 из 350. Различие overall объясняется весами групп: у exact лучше Irrelevance, но хуже Simple и Parallel.

5. Ход обучения

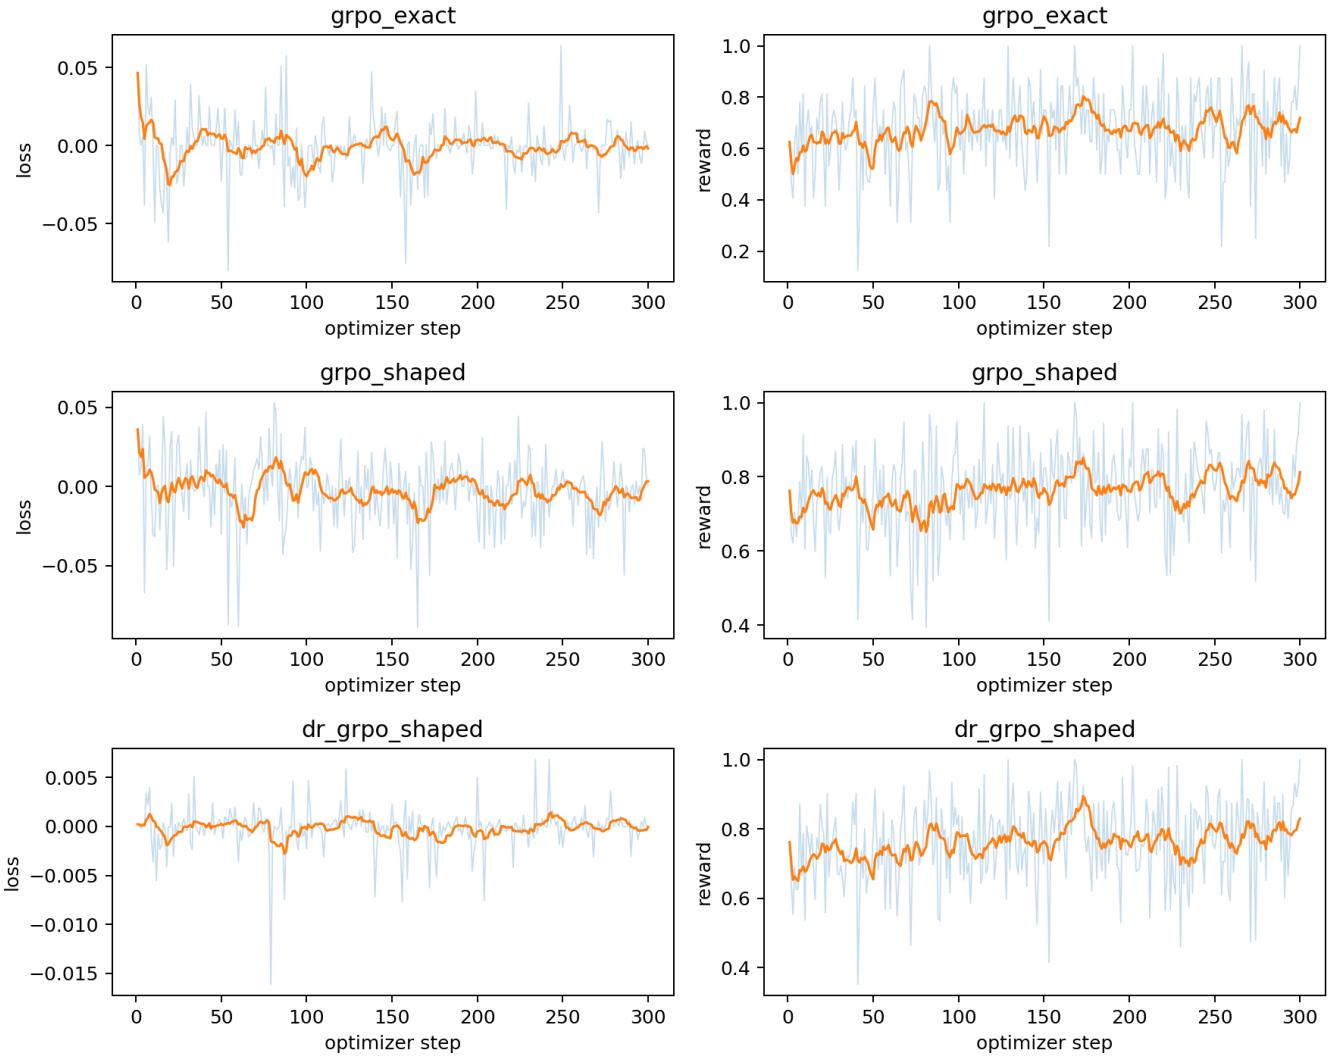


Рис. 2. Для каждого запуска показаны policy loss с KL и сырая награда. Бледная линия - отдельные шаги, сплошная - среднее по 10 шагам. У GRPO и Dr. GRPO разная нормировка loss, его абсолютные значения напрямую не сравниваются.

Ответ 3. За первые/последние 20 шагов средняя награда выросла: exact 0.627 → 0.723, shaped 0.737 → 0.802, Dr. GRPO shaped 0.717 → 0.826. Награды разных форм напрямую не сравниваются. При одной составной награде Dr. GRPO заканчивает с большим средним reward, но с чуть меньшим BFCL; эта разница BFCL мала относительно интервала неопределённости. Промежуточный BFCL не замерялся, поэтому корреляцию по шагам установить нельзя.
На одинаковой ToolACE validation exact выигрывает у shaped по exact match: 77.60% против 73.44%, а на BFCL порядок обратный. В validation треть примеров без вызова; у BFCL группа Irrelevance весит одну пятую. Exact лучше отказывается от вызовов: 92.19% против 75.00% на validation, 84% против 60% на BFCL. Shaped лучше выполняет вызовы: например, Parallel 80% против 48%. Доля групп с одинаковой наградой снизилась с 82.75% у exact до 75.54% у shaped, что согласуется с более частым различающим сигналом. Случай parallel_multiple_67 дополнительно показывает несовпадение правил: награда считает 1 и 1.0 равными, а AST-checker требует float внутри массива.

6. Оставшиеся ошибки

Ответ 5. Ниже разобраны ошибки лучшего наблюдаемого варианта: grpo_shaped. Полные ответы и результаты AST-проверки сохранены в predictions.jsonl. Запросы сокращены, вызовы показаны после разбора parser; текстовые ответы приведены фрагментами.

simple_150 / simple

Запрос (кратко): Рассчитать доход от вклада $1000 под 3% годовых за один год.

Ожидалось: calculate_roi(deposit=1000, annual_interest_rate=0.03, years=1).

Получено: {"calculate_roi": {"deposit": 1000, "annual_interest_rate": 3, "years": 1}}

Функция выбрана правильно, но процент передан как 3 вместо 0.03. Остаётся ошибка нормализации единиц, хотя разметка корректна.

multiple_76 / multiple

Запрос (кратко): Заказать бронзовую скульптуру лошади и узнать доступные материалы.

Ожидалось: Вызов sculpture.create_custom с item="horse" и material="Bronze".

Получено: The available materials for a custom bronze sculpture are:
* Bronze
* Marble
* Terracotta
* Wood
* Stone

Нужный вызов пропущен: модель перечисляет материалы текстом, но parsed calls пуст. Запрос допускает и чтение как вопрос о материалах, однако эталон BFCL требует создание скульптуры. По неизменённому checker это ошибка.

parallel_181 / parallel

Запрос (кратко): Получить цены Apple, Microsoft, Amazon и Tesla за 1, 2, 3 недели и месяц соответственно.

Ожидалось: Четыре get_stock_prices: Apple/1 week, Microsoft/2 weeks, Amazon/3 weeks, Tesla/1 month.

Получено: {"get_stock_prices": {"companies": ["Apple", "Microsoft", "Amazon", "Tesla"], "duration": "1 week"}}

Здесь показан первый из четырёх вызовов. В каждом модель передаёт сразу все компании, меняя только duration. Число вызовов верно, но потеряно соответствие «компания - период».

Оставшиеся ошибки: продолжение

parallel_multiple_67 / parallel_multiple

Запрос (кратко): Найти корни квадратного, кубического и полиномиального уравнений; коэффициенты последнего: [6, -3, 2, -1, 1].

Ожидалось: Три вызова; у math.roots.polynomial массив coefficients должен содержать float: [6.0, -3.0, 2.0, -1.0, 1.0].

Получено: {"math.roots.polynomial": {"coefficients": [6, -3, 2, -1, 1]}}

Показан третий вызов. Числа по смыслу верны, но checker отклоняет вложенный тип int вместо float. Это конкретный разрыв с числовой нормализацией в reward. Правила evaluator сохранены.

irrelevance_233 / irrelevance

Запрос (кратко): Перевести $20 в британские фунты; доступен только инструмент погоды.

Ожидалось: Никакого вызова: у доступной weather_in_location нет функции обмена валют.

Получено: {"weather_in_location": {"location": "London", "unit": "C"}}

Лишний вызов: модель привязала фунты к Лондону и запросила погоду. Она узнаёт знакомый инструмент, но не проверяет соответствие его назначения запросу.

Ограничения и итог

Это 350 тестовых примеров и один seed на конфигурацию. Bootstrap отражает разброс тестовой выборки, но не нестабильность обучения. Лучший метод выбран по этому срезу BFCL; вывод ограничен данной серией. ToolACE reward и BFCL используют разные правила, а полезность текста без вызова отдельно не измеряется. Время включает инициализацию и влияние кэшей; отдельного сравнения скорости алгоритмов не проводилось.

Составная награда дала заметный прирост качества вызовов при том же бюджете. GRPO shaped получил максимум overall, Dr. GRPO показал сопоставимый результат и более высокий Irrelevance: 68% против 60%. Дальнейшая проверка потребовала бы нескольких seed и отдельной тестовой выборки; текущие результаты не позволяют уверенно ранжировать эти два варианта.

Материалы

Модель и её описание

ToolACE

TRL GRPOTrainer 1.16.0

Условие задания